

Machine Learning

(Mesin Pembelajaran)





Machine Learning

“ ... a computer program that can learn from *experience* with respect to some class of *tasks* and *performance* measure ... ”

(Mitchell, 1997)

“ ... the capacity of a computer to learn from *experience*, i.e. to *modify* its processing on the basis of newly acquired *information* ... ”

(Oxford English Dictionary, 1989)



Termasuk ML

- Artificial Neural Networks
- Boosting
- Hidden Markov Models
- Bayesian
- Regresi
- Support Vector Machines
- Decision Tree
- Dan lainnya



- Jika kita punya sehimpunan big data yang perlu model yang rumit, kerangka kerja Bayesian secara komputasi sangat mahal
- Apakah ada metode yang biasa yang lebih cepat tetapi bisa generalisasi dengan baik?



Support Vector Machine (SVM)



Pokok Pembahasan

1. Support Vector Machine (SVM)
 - ✓ Pengertian SVM
 - ✓ Model SVM
 - ✓ Visualisasi SVM
 - ✓ Karakteristik SVM
2. Case Study
3. Latihan Individu & Diskusi Kelompok



Support Vector Machine

- Konsep Klasifikasi dengan Support Vector Machine (SVM) adalah mencari hyperplane terbaik yang berfungsi sebagai pemisah dua kelas data.
- Ide sederhana dari SVM adalah memaksimalkan margin, yang merupakan jarak pemisah antara kelas data.
- SVM mampu bekerja pada dataset yang berdimensi tinggi dengan menggunakan kernel trik.
- SVM hanya menggunakan beberapa titik data terpilih yang berkontribusi (Support Vector) untuk membentuk model yang akan digunakan dalam proses klasifikasi.
- Macam-Macam Training untuk SVM :
 - Chunking (Quadratic Programming).
 - Osuna (Dekomposisi).
 - Sequential Minimum Optimation (SMO).
 - Least Square (LS) dan lainnya.



Model SVM

- Titik data : $x_i = \{x_1, x_2, \dots, x_n\} \in \mathbb{R}^n$
- Kelas data : $y_i \in \{-1, +1\}$
- Pasangan data dan kelas : $\{(x_i, y_i)\}_{i=1}^N$
- Maksimalkan fungsi berikut :

$$Ld = \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) \text{ syarat : } 0 \leq \alpha_i \leq C \text{ dan } \sum_{i=1}^N \alpha_i y_i = 0$$

- Hitung nilai w dan b :

$$w = \sum_{i=1}^N \alpha_i y_i x_i \quad b = -\frac{1}{2} (w \cdot x^+ + w \cdot x^-)$$

- Fungsi keputusan klasifikasi $\text{sign}(f(x))$:

$$f(x) = w \cdot x + b \quad \text{atau} \quad f(x) = \sum_{i=1}^m \alpha_i y_i K(x, x_i) + b$$

Keterangan :

N (banyaknya data), n (dimensi data atau banyaknya fitur), Ld (Dualitas Lagrange Multiplier), α_i (nilai bobot setiap titik data), C (nilai konstanta), m (jumlah support vector/titik data yang memiliki $\alpha_i > 0$), $K(x, x_i)$ (fungsi kernel).



Model SVM (Cont.)

- Beberapa Macam Fungsi Kernel Support Vector Machine (SVM) :


No	Nama Kernel	Definisi Fungsi
1	Linier	$K(x,y) = x.y$
2	Polinomial of degree d	$K(x,y) = (x.y)^d$
3	Polinomial of degree up to d	$K(x,y) = (x.y + c)^d$
4	Gaussian RBF	$K(x,y) = \exp\left(\frac{-\ x-y\ ^2}{2\sigma^2}\right)$
5	Sigmoid (Tangen Hiperbolik)	$K(x,y) = \tanh(\sigma(x.y)+c)$
6	Invers Multi Kuadratik	$K(x,y) = \frac{1}{\sqrt{\ x-y\ ^2+c^2}}$
7	Additive	$K(x,y) = \sum_{i=1}^n K_i(x_i, y_i)$

- Kernel Linier digunakan ketika data yang akan diklasifikasi dapat terpisah dengan sebuah garis/hyperplane.
- Kernel non-Linier digunakan ketika data hanya dapat dipisahkan dengan garis lengkung atau sebuah bidang pada ruang dimensi tinggi (Kernel Trik, No.2 sampai 6).



Visualisasi SVM

- Linier Kernel :



$$\text{Margin} = \frac{2}{\|w\|} = \frac{2}{\sqrt{w_1^2 + w_2^2}}$$

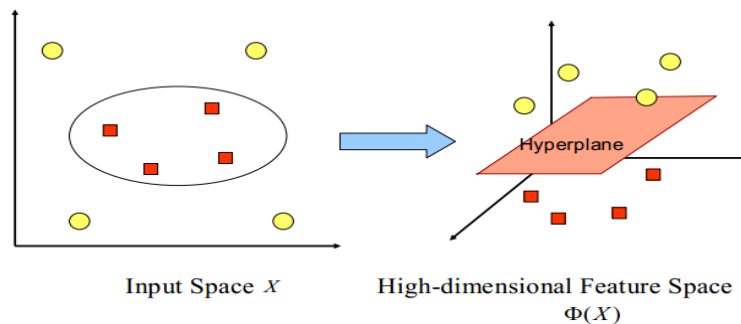
- Support Vector kelas -1
- Support Vector kelas +1

● Jarak titik (x_i) ke Hyperplane :

$$d((w, b), x_i) = \frac{y_i (x_i \bullet w + b)}{\|w\|} \geq \frac{1}{\|w\|}$$

$$d((w, b), x_i) = \frac{y_i f(x_i)}{\|w\|} \geq \frac{1}{\|w\|}$$

- Non-Linier Kernel :





Memaksimumkan margin


Rumus jarak dari titik $T(x_1, y_1)$ ke garis $ax + by + c = 0$ adalah :

$$d = \frac{|ax_1 + by_1 + c|}{\sqrt{a^2 + b^2}}$$

Recall: jarak dari suatu titik (x_0, y_0) ke suatu garis $Ax + By + c = 0$ adalah $d = |Ax_0 + By_0 + c| / \sqrt{A^2 + B^2}$

Jarak antara H and H1 adalah:
 $|w \cdot x + b| / \|w\| = 1 / \|w\|$

Jarak antara H1 dan H2 adalah : $2 / \|w\|$



Untuk memaksimumkan margin, diperlukan cara $\|w\|$, dengan syarat tidak ada titik-titik data antara H1 and H2:

$x_i \cdot w + b \geq +1$ when $y_i = +1$
 $x_i \cdot w + b \leq -1$ when $y_i = -1$

Can be combined into $y_i(x_i \cdot w) \geq 1$



Karakteristik SVM

- Karakteristik SVM :
 - SVM memerlukan proses pelatihan dengan menyimpan hasil support vektor yang didapatkan untuk digunakan kembali pada saat proses prediksi/testing.
 - SVM selalu memberikan model yang sama dan solusi yang sama dengan margin maksimal.
 - SVM dapat memisahkan data yang distribusi kelasnya bersifat linier maupun non linier.
 - SVM tidak dipengaruhi oleh dimensi data yang tinggi, sehingga tidak ada proses reduksi dimensi didalamnya.
 - Memori yang digunakan dalam SVM dipengaruhi oleh banyaknya data, bukan besarnya dimensi data.




Contoh Studi Kasus

- Contoh SVM Linier pada dataset berikut :
Tentukan Hyperplanenya !

x_1	x_2	Kelas (y)	Support Vector (SV)
1	1	1	1
1	-1	-1	1
-1	1	-1	1
-1	-1	-1	0

- Bentuk Visualisasi data :






Contoh Studi Kasus 1 (Cont.)

- Contoh SVM Linier :

x_1	x_2	Kelas (y)
1	1	1
1	-1	-1
-1	1	-1
-1	-1	-1



- Karena ada dua fitur (x_1 dan x_2), maka w juga akan memiliki 2 fitur (w_1 dan w_2).
- Formulasi yang digunakan adalah sebagai berikut :

- Meminimalkan nilai :

$$\frac{1}{2} \|w\|^2 = \frac{1}{2} (w_1^2 + w_2^2)$$

- Syarat :

$$y_i(w \cdot x_i + b) \geq 1, \quad i = 1, 2, 3, \dots, N$$



Contoh Studi Kasus 1 (Cont.)

- Karena ada dua fitur (x_1 dan x_2), maka w juga akan memiliki 2 fitur (w_1 dan w_2).
- Formulasi yang digunakan adalah sebagai berikut :

- Meminimalkan nilai margin :

$$\frac{1}{2} \|w\|^2 = \frac{1}{2} (w_1^2 + w_2^2)$$

- Syarat :

$$y_i(w \cdot x_i + b) \geq 1, \quad i = 1, 2, 3, \dots, N$$
$$y_i(w_1 \cdot x_1 + w_2 \cdot x_2 + b) \geq 1$$

x_1	x_2	Kelas (y)
1	1	1
1	-1	-1
-1	1	-1
-1	-1	-1

Sehingga didapatkan beberapa persamaan berikut :

1. $(w_1 + w_2 + b) \geq 1$, untuk $y_1 = 1, x_1 = 1, x_2 = 1$
2. $(-w_1 + w_2 - b) \geq 1$, untuk $y_2 = -1, x_1 = 1, x_2 = -1$
3. $(w_1 - w_2 - b) \geq 1$, untuk $y_3 = -1, x_1 = -1, x_2 = 1$
4. $(w_1 + w_2 - b) \geq 1$, untuk $y_4 = -1, x_1 = -1, x_2 = -1$



Contoh Studi Kasus 1 (Cont.)

Didapatkan beberapa persamaan berikut :

1. $(w_1 + w_2 + b) \geq 1$
2. $(-w_1 + w_2 - b) \geq 1$
3. $(w_1 - w_2 - b) \geq 1$
4. $(w_1 + w_2 - b) \geq 1$

- Menjumlahkan persamaan (1) dan (2) :

$$\begin{array}{r} (w_1 + w_2 + b) \geq 1 \\ (-w_1 + w_2 - b) \geq 1 \\ \hline 2w_2 = 2 \\ \text{Maka } w_2 = 1 \end{array}$$

- Menjumlahkan persamaan (1) dan (3) :

$$\begin{array}{r} (w_1 + w_2 + b) \geq 1 \\ (w_1 - w_2 - b) \geq 1 \\ \hline 2w_1 = 2 \\ \text{Maka } w_1 = 1 \end{array}$$

- Menjumlahkan persamaan (2) dan (3) :

$$\begin{array}{r} (-w_1 + w_2 - b) \geq 1 \\ (w_1 - w_2 - b) \geq 1 \\ \hline -2b = 2 \\ \text{Maka } b = -1 \end{array}$$

Sehingga didapatkan persamaan hyperplane :

$$w_1x_1 + w_2x_2 + b = 0$$

$$x_1 + x_2 - 1 = 0$$

$$x_2 = 1 - x_1$$



Contoh Studi Kasus 1 (Cont.)

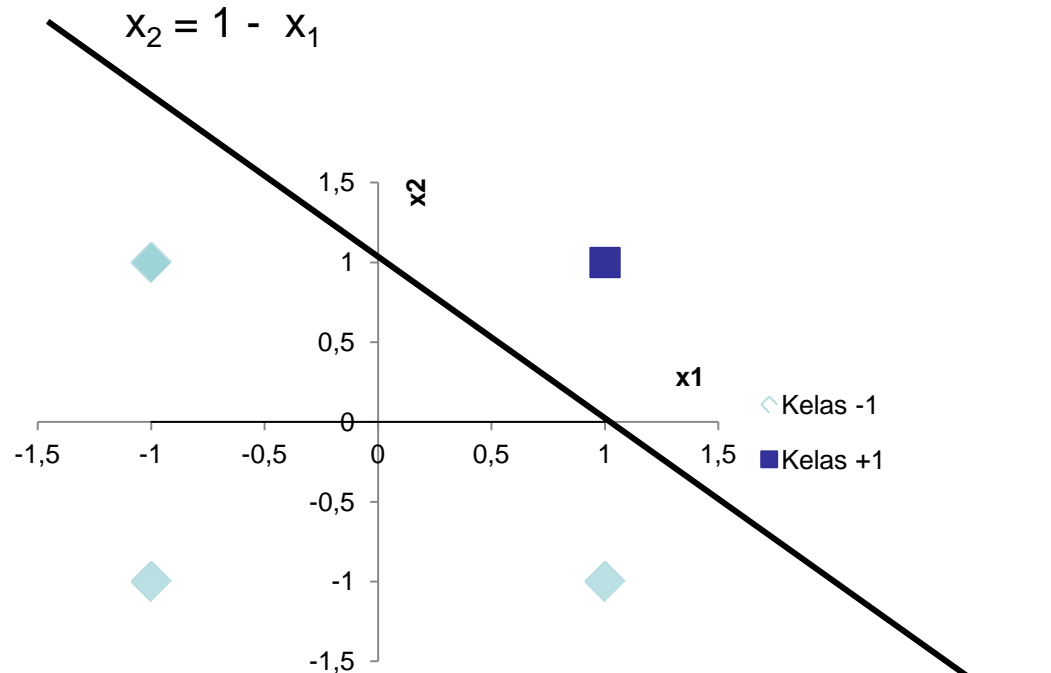
Visualisasi garis hyperplane (sebagai fungsi klasifikasi) :

$$w_1x_1 + w_2x_2 + b = 0$$

$$x_1 + x_2 - 1 = 0$$

$$x_2 = 1 - x_1$$

x_1	$x_2 = 1 - x_1$
-2	3
-1	2
0	1
1	0
2	-1






Contoh Studi Kasus 1 (Cont.)

Misalkan diketahui data uji/ data testing berikut :

$$\text{Diketahui : } f(x) = x_1 + x_2 - 1$$

$$\text{Kelas} = \text{sign}(f(x))$$

No	Data Uji		Hasil Klasifikasi
	x_1	x_2	$\text{Kelas} = \text{sign}(x_1 + x_2 - 1)$
1	1	5	$\text{sign}(1 + 5 - 1) = +1$
2	-1	4	$\text{sign}(-1 + 4 - 1) = +1$
3	0	7	$\text{sign}(0 + 7 - 1) = +1$
4	-9	0	$\text{sign}(-9 + 0 - 1) = -1$
5	2	-2	$\text{sign}(2 - 2 - 1) = -1$






Contoh Studi Kasus 2

- Contoh SVM Non Linier pada dataset berikut :

x_1	x_2	Kelas (y)	Support Vector (SP)
1	1	-1	1
1	-1	1	1
-1	1	1	1
-1	-1	-1	1

- Bentuk Visualisasi data :






Contoh Studi Kasus 2 (Cont.)

- Contoh SVM Non Linier :

x_1	x_2	Kelas (y)
1	1	-1
1	-1	1
-1	1	1
-1	-1	-1



- Karena ada dua fitur (x_1 dan x_2), dan kelompok datanya tidak linear, maka digunakan fungsi kernel. Misal menggunakan fungsi kernel polynomial ordo 2, yaitu :

$$\mathbf{K}(\mathbf{x}, \mathbf{y}) = (\mathbf{x} \cdot \mathbf{y} + \mathbf{c})^d \quad \text{dengan } c = 1 \text{ dan } d = 2.$$

- Fungsi kernel dituliskan kembali menjadi berikut :

$$\mathbf{K}(\mathbf{x}, \mathbf{x}_i) = (\mathbf{x}^T \cdot \mathbf{x}_i + 1)^2 \quad \text{dengan } w = \sum_{i=1..N} \alpha_i y_i \phi(x_i)$$

- Menghitung matrik kernel K :

$$\mathbf{K}(\mathbf{x}, \mathbf{x}_i) = \Phi(\mathbf{x}) \cdot \Phi(\mathbf{x}_i)$$



Contoh Studi Kasus 2 (Cont.)

- Fungsi kernel dituliskan kembali menjadi berikut :

$$\mathbf{K}(\mathbf{x}, \mathbf{x}_i) = (\mathbf{x}^T \cdot \mathbf{x}_i + 1)^2 \text{ dengan } w = \sum_{i=1 \dots N} \alpha_i y_i \phi(x_i)$$

- Menghitung matrik kernel $\mathbf{K}(\mathbf{x}, \mathbf{x}_i) = \Phi(\mathbf{x}) \cdot \Phi(\mathbf{x}_i)$

- Misal, Menghitung $K(u, z)$: dengan $u=(1,1)$ dan $z=(1,-1)$

x_1	x_2	Kelas (y)
1	1	-1
1	-1	1
-1	1	1
-1	-1	-1

$$k(u=(1,1), z=(1,-1)) = (((u_1 \cdot z_1) + (u_2 \cdot z_2)) + 1)^2 = ((u_1 \cdot z_1) + (u_2 \cdot z_2))^2 + 2((u_1 \cdot z_1) + (u_2 \cdot z_2)) \cdot 1 + 1^2$$

$$= (u_1 \cdot z_1)^2 + 2(u_1 \cdot z_1)(u_2 \cdot z_2) + (u_2 \cdot z_2)^2 + 2(u_1 \cdot z_1) + 2(u_2 \cdot z_2) + 1$$

$$= \begin{pmatrix} u_1^2 \\ \sqrt{2}u_1u_2 \\ u_2^2 \\ \sqrt{2}u_1 \\ \sqrt{2}u_2 \\ 1 \end{pmatrix} \cdot \begin{pmatrix} z_1^2 \\ \sqrt{2}z_1z_2 \\ z_2^2 \\ \sqrt{2}z_1 \\ \sqrt{2}z_2 \\ 1 \end{pmatrix}$$

$$= \phi(u) \cdot \phi(z)$$

$$= u_1^2 z_1^2 + 2u_1 u_2 z_1 z_2 + u_2^2 z_2^2 + 2u_1 z_1 + 2u_2 z_2 + 1$$

$$= (u_1 z_1)^2 + 2(u_1 z_1)(u_2 z_2) + (u_2 z_2)^2 + 2(u_1 z_1) + 2(u_2 z_2) + 1$$



Contoh Studi Kasus 2 (Cont.)

- Fungsi kernel dituliskan kembali menjadi berikut :

$$\mathbf{K}(\mathbf{x}, \mathbf{x}_i) = (\mathbf{x}^T \cdot \mathbf{x}_i + 1)^2 \text{ dengan } w = \sum_{i=1 \dots N} \alpha_i y_i \phi(x_i)$$

- Menghitung matrik kernel $\mathbf{K}(\mathbf{x}, \mathbf{x}_i) = \Phi(\mathbf{x}) \cdot \Phi(\mathbf{x}_i)$

- Misal, Menghitung $K(u, z)$: dengan $u=(1,1)$ dan $z=(1,-1)$

x_1	x_2	Kelas (y)
1	1	-1
1	-1	1
-1	1	1
-1	-1	-1

$$k(u=(1,1), z=(1,-1)) = (((u_1 \cdot z_1) + (u_2 \cdot z_2)) + 1)^2 = ((u_1 \cdot z_1) + (u_2 \cdot z_2))^2 + 2((u_1 \cdot z_1) + (u_2 \cdot z_2)) \cdot 1 + 1^2$$

$$= (u_1 \cdot z_1)^2 + 2(u_1 \cdot z_1)(u_2 \cdot z_2) + (u_2 \cdot z_2)^2 + 2(u_1 \cdot z_1) + 2(u_2 \cdot z_2) + 1$$

$$= \begin{pmatrix} u_1^2 \\ \sqrt{2}u_1u_2 \\ u_2^2 \\ \sqrt{2}u_1 \\ \sqrt{2}u_2 \\ 1 \end{pmatrix} \cdot \begin{pmatrix} z_1^2 \\ \sqrt{2}z_1z_2 \\ z_2^2 \\ \sqrt{2}z_1 \\ \sqrt{2}z_2 \\ 1 \end{pmatrix}$$

$$= \phi(u) \cdot \phi(z)$$

$$= u_1^2 z_1^2 + 2u_1 u_2 z_1 z_2 + u_2^2 z_2^2 + 2u_1 z_1 + 2u_2 z_2 + 1$$

$$= (u_1 z_1)^2 + 2(u_1 z_1)(u_2 z_2) + (u_2 z_2)^2 + 2(u_1 z_1) + 2(u_2 z_2) + 1$$



Contoh Studi Kasus 2 (Cont.)

- Misal, Menghitung $K(u,z)$: dengan $u=(1,1)$ dan $z=(1,-1)$

$$\begin{aligned}k(u=(1,1), z=(1,-1)) &= (((1.1)+(1.(-1)))+1)^2 = ((1.1)+(1.(-1)))^2 + 2((1.1)+(1.(-1))).1 + 1^2 \\&= (1.1)^2 + 2(1.1)(1.(-1)) + (1.(-1))^2 + 2(1.1) + 2(1.(-1)) + 1 \\&= 1 - 2 + 1 + 2 - 2 + 1 = 1\end{aligned}$$

$$= \begin{pmatrix} u_1^2 \\ \sqrt{2}u_1u_2 \\ u_2^2 \\ \sqrt{2}u_1 \\ \sqrt{2}u_2 \\ 1 \end{pmatrix} \cdot \begin{pmatrix} z_1^2 \\ \sqrt{2}z_1z_2 \\ z_2^2 \\ \sqrt{2}z_1 \\ \sqrt{2}z_2 \\ 1 \end{pmatrix} = \begin{pmatrix} 1^2 \\ \sqrt{2}.1.1 \\ 1^2 \\ \sqrt{2}.1 \\ \sqrt{2}.1 \\ 1 \end{pmatrix} \cdot \begin{pmatrix} 1^2 \\ \sqrt{2}.1.(-1) \\ (-1)^2 \\ \sqrt{2}.1 \\ \sqrt{2}.(-1) \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ \sqrt{2} \\ 1 \\ \sqrt{2} \\ \sqrt{2} \\ 1 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ -\sqrt{2} \\ 1 \\ \sqrt{2} \\ -\sqrt{2} \\ 1 \end{pmatrix} = 1 - 2 + 1 + 2 - 2 + 1 = 1$$

$$= \phi(u) \cdot \phi(z)$$

$$= u_1^2 z_1^2 + 2u_1 u_2 z_1 z_2 + u_2^2 z_2^2 + 2u_1 z_1 + 2u_2 z_2 + 1$$

$$= (u_1 z_1)^2 + 2(u_1 z_1)(u_2 z_2) + (u_2 z_2)^2 + 2(u_1 z_1) + 2(u_2 z_2) + 1$$



Contoh Studi Kasus 2 (Cont.)

- Menghitung matrik kernel $K(\mathbf{x}, \mathbf{x}_i) = \Phi(\mathbf{x}) \cdot \Phi(\mathbf{x}_i)$

x_1	x_1	$K(1,1) = (x_1.x_1 + 1)^2 = (1.1 + 1.1 + 1)^2 = 3^2 = 9$
	x_2	$K(1,2) = (x_1.x_2 + 1)^2 = (1.1 + 1.(-1) + 1)^2 = 1^2 = 1$
	x_3	$K(1,3) = (x_1.x_3 + 1)^2 = (1.(-1) + 1.1 + 1)^2 = 1^2 = 1$
	x_4	$K(1,4) = (x_1.x_4 + 1)^2 = (1.(-1) + 1.(-1) + 1)^2 = (-1)^2 = 1$
x_2	x_1	$K(2,1) = (x_2.x_1 + 1)^2 = (1.1 + (-1).1 + 1)^2 = 1^2 = 1$
	x_2	$K(2,2) = (x_2.x_2 + 1)^2 = (1.1 + (-1).(-1) + 1)^2 = 3^2 = 9$
	x_3	$K(2,3) = (x_2.x_3 + 1)^2 = (1.(-1) + (-1).1 + 1)^2 = 1^2 = 1$
	x_4	$K(2,4) = (x_2.x_4 + 1)^2 = (1.(-1) + (-1).(-1) + 1)^2 = 1^2 = 1$
x_3	x_1	$K(3,1) = (x_3.x_1 + 1)^2 = ((-1).1 + 1.1 + 1)^2 = 1^2 = 1$
	x_2	$K(3,2) = (x_3.x_2 + 1)^2 = ((-1).1 + 1.(-1) + 1)^2 = 1^2 = 1$
	x_3	$K(3,3) = (x_3.x_3 + 1)^2 = ((-1).(-1) + 1.1 + 1)^2 = 3^2 = 9$
	x_4	$K(3,4) = (x_3.x_4 + 1)^2 = ((-1).(-1) + 1.(-1) + 1)^2 = 1^2 = 1$
x_4	x_1	$K(4,1) = (x_4.x_1 + 1)^2 = ((-1).1 + (-1).1 + 1)^2 = 1^2 = 1$
	x_2	$K(4,2) = (x_4.x_2 + 1)^2 = ((-1).1 + (-1).(-1) + 1)^2 = 1^2 = 1$
	x_3	$K(4,3) = (x_4.x_3 + 1)^2 = ((-1).(-1) + (-1).1 + 1)^2 = 1^2 = 1$
	x_4	$K(4,4) = (x_4.x_4 + 1)^2 = ((-1).(-1) + (-1).(-1) + 1)^2 = 3^2 = 9$

x_1	x_2	Kelas (y)
1	1	-1
1	-1	1
-1	1	1
-1	-1	-1



Contoh Studi Kasus 2 (Cont.)

- Didapatkan matrik kernel K dengan ukuran N x N :

$K(x, x_i) =$

9	1	1	1
1	9	1	1
1	1	9	1
1	1	1	9

x_1	x_2	Kelas (y)
1	1	-1
1	-1	1
-1	1	1
-1	-1	-1

- Setiap elemen matrik kernel $K(x, x_i)$ digunakan untuk menggantikan dot-product $\mathbf{x}_i \cdot \mathbf{x}_j$ dalam persamaan dualitas Lagrange Multiplier.

- Maksimalkan Ld :

$$Ld = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j (x_i \cdot x_j)$$

$$Ld = (\alpha_1 + \alpha_2 + \alpha_3 + \alpha_4) - \frac{1}{2} \begin{pmatrix} 9\alpha_1\alpha_1 - 1\alpha_1\alpha_2 - 1\alpha_1\alpha_3 + 1\alpha_1\alpha_4 - \\ 1\alpha_2\alpha_1 + 9\alpha_2\alpha_2 + 1\alpha_2\alpha_3 - 1\alpha_2\alpha_4 - \\ 1\alpha_3\alpha_1 + 1\alpha_3\alpha_2 + 9\alpha_3\alpha_3 - 1\alpha_3\alpha_4 + \\ 1\alpha_4\alpha_1 - 1\alpha_4\alpha_2 - 1\alpha_4\alpha_3 + 9\alpha_4\alpha_4 \end{pmatrix}$$



Contoh Studi Kasus 2 (Cont.)

- Setiap elemen matrik kernel $K(x, x_i)$ digunakan untuk menggantikan dot-product $\mathbf{x}_i \cdot \mathbf{x}_j$ dalam persamaan dualitas Lagrange Multiplier.
 - Maksimalkan L_d :

x_1	x_2	Kelas (y)
1	1	-1
1	-1	1
-1	1	1
-1	-1	-1

$$L_d = (\alpha_1 + \alpha_2 + \alpha_3 + \alpha_4) - \frac{1}{2} \begin{pmatrix} 9\alpha_1^2 - 2\alpha_1\alpha_2 - 2\alpha_1\alpha_3 + 2\alpha_1\alpha_4 + \\ 9\alpha_2^2 + 2\alpha_2\alpha_3 - 2\alpha_2\alpha_4 + \\ 9\alpha_3^2 - 2\alpha_3\alpha_4 + 9\alpha_4^2 \end{pmatrix}$$

$$\text{Syarat : } 0 \leq \alpha_i \leq C \text{ dan } \sum_{i=1}^N \alpha_i y_i = 0$$

$$\text{Syarat 1 : } \alpha_1, \alpha_2, \alpha_3, \alpha_4 \geq 0$$

$$\text{Syarat 2 : } -\alpha_1 + \alpha_2 + \alpha_3 - \alpha_4 = 0$$

(Note : Untuk hasil optimal L_d , gunakan koding)

- Misalkan didapatkan nilai Max L_d dengan $\alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = 0.125$. Sehingga nilai $L_d = 0.25$.

- Hitung nilai w dan b : $X_i = \begin{pmatrix} x_1^i \\ x_2^i \end{pmatrix}$, jika X_1 adalah data ke-1,

$$X_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \phi(X_i) = \begin{pmatrix} x_1^{i^2} & \sqrt{2}x_1^i x_2^i & x_2^{i^2} & \sqrt{2}x_1^i & \sqrt{2}x_2^i & 1 \end{pmatrix}^T$$

dimana x_1^i adalah nilai pada dimensi ke-1 pada data ke-i.



Contoh Studi Kasus 2 (Cont.)

- Hitung nilai w dan b : $X_i = \begin{pmatrix} x_1^i \\ x_2^i \end{pmatrix}$, jika X_1 adalah data ke-1,

$$X_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \phi(X_i) = \begin{pmatrix} x_1^{i^2} & \sqrt{2}x_1^i x_2^i & x_2^{i^2} & \sqrt{2}x_1^i & \sqrt{2}x_2^i & 1 \end{pmatrix}^T$$

dimana x_1^i adalah nilai pada dimensi ke-1 pada data ke- i .

x_1	x_2	Kelas (y)
1	1	-1
1	-1	1
-1	1	1
-1	-1	-1

$$w = \sum_{i=1}^N \alpha_i y_i \phi(X_i)$$

$$w = \sum_{i=1}^N \alpha_i y_i \phi(X_i) = \sum_{i=1}^4 \alpha_i y_i \phi(X_i) = \alpha_1 y_1 \phi(X_1) + \alpha_2 y_2 \phi(X_2) + \alpha_3 y_3 \phi(X_3) + \alpha_4 y_4 \phi(X_4)$$

$$w = -0.125 \begin{pmatrix} x_1^{1^2} = 1^2 = 1 \\ \sqrt{2}x_1^1 x_2^1 = \sqrt{2}(1)(1) = \sqrt{2} \\ x_2^{1^2} = 1^2 = 1 \\ \sqrt{2}x_1^1 = \sqrt{2}(1) = \sqrt{2} \\ \sqrt{2}x_2^1 = \sqrt{2}(1) = \sqrt{2} \\ 1 \end{pmatrix} + 0.125 \begin{pmatrix} 1 \\ -\sqrt{2} \\ 1 \\ \sqrt{2} \\ -\sqrt{2} \\ 1 \end{pmatrix} + 0.125 \begin{pmatrix} 1 \\ -\sqrt{2} \\ 1 \\ -\sqrt{2} \\ \sqrt{2} \\ 1 \end{pmatrix} - 0.125 \begin{pmatrix} 1 \\ \sqrt{2} \\ 1 \\ -\sqrt{2} \\ -\sqrt{2} \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ -0.71 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$



Contoh Studi Kasus 2 (Cont.)

- Misalkan didapatkan nilai Max Ld dengan $\alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = 0.125$.

Sehingga nilai Ld = 0.25.

- Hitung nilai w dan b :

$$w = \sum_{i=1}^N \alpha_i y_i \phi(X_i) = \begin{pmatrix} 0 \\ -0.71 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

x_1	x_2	Kelas (y)
1	1	-1
1	-1	1
-1	1	1
-1	-1	-1

Pilih salah satu Support Vector dari Kelas “+1” dan “-1” untuk menghitung nilai b.

$$b = -\frac{1}{2} (w \cdot x^+ + w \cdot x^-) = -\frac{1}{2} \left(\begin{pmatrix} 0 \\ -0.71 \\ 0 \\ 0 \\ 0 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ -\sqrt{2} \\ 1 \\ \sqrt{2} \\ 1 \end{pmatrix} + \begin{pmatrix} 0 \\ -0.71 \\ 0 \\ 0 \\ 0 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ \sqrt{2} \\ 1 \\ -\sqrt{2} \\ 1 \end{pmatrix} \right)$$



Contoh Studi Kasus 2 (Cont.)

- Misalkan didapatkan nilai Max Ld dengan $\alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = 0.125$. Sehingga nilai Ld = 0.25.
- Hitung nilai w dan b :

x_1	x_2	Kelas (y)
1	1	-1
1	-1	1
-1	1	1
-1	-1	-1

Pilih salah satu Support Vector dari Kelas “+1” dan “-1” untuk menghitung nilai b.

$$b = -\frac{1}{2}(w.x^+ + w.x^-) = -\frac{1}{2} \left(\begin{pmatrix} 0 \\ -0.71 \\ 0 \\ 0 \\ 0 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ -\sqrt{2} \\ \sqrt{2} \\ -\sqrt{2} \\ 1 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ \sqrt{2} \\ \sqrt{2} \\ \sqrt{2} \\ 1 \end{pmatrix} \right)$$

$$b = -\frac{1}{2}((-0.71)(-\sqrt{2}) + (-0.71)(\sqrt{2})) = -\frac{1}{2}((-0.71)(-\sqrt{2}) + (-0.71)(\sqrt{2})) = 0$$



Contoh Studi Kasus 2 (Cont.)

- Setelah didapatkan nilai w dan b :

$$w = \begin{pmatrix} 0 \\ -0.71 \\ 0 \\ 0 \\ 0 \\ 0 \end{pmatrix} \quad b = 0$$

$$\begin{aligned} w \cdot \phi(x_t) + b &= w \cdot \phi(x_t) + 0 \\ &= \sum_{i=1}^N \alpha_i y_i \phi(x_i) \cdot \phi(x_t) = \sum_{i=1}^4 \alpha_i y_i K(x_i, x_t) \end{aligned}$$

x_1	x_2	Kelas (y)
1	1	-1
1	-1	1
-1	1	1
-1	-1	-1

Maka model SVM siap digunakan untuk proses klasifikasi.

$$f(\phi(x)) = \text{sign}(w \cdot \phi(x) + b) = \text{sign}\left(\sum_{i=1}^N \alpha_i y_i \phi(x_i) \cdot \phi(x) + b\right)$$

Misalkan data uji/ data test $x_t = (1,5)$ maka $K(x_i, x_t) = \phi(x_i) \cdot \phi(x_t)$

$x_t = (1,5)$	x_1	$K(1,t) = (x_1 \cdot x_t + 1)^2 = (1 \cdot 1 + 5 \cdot 1 + 1)^2 = 7^2 = 49$	$(-0.125)(49)$
	x_2	$K(2,t) = (x_2 \cdot x_t + 1)^2 = (1 \cdot 1 + 5 \cdot (-1) + 1)^2 = 3^2 = 9$	$(0.125)(9)$
	x_3	$K(3,t) = (x_3 \cdot x_t + 1)^2 = (1 \cdot (-1) + 5 \cdot 1 + 1)^2 = 5^2 = 25$	$(0.125)(25)$
	x_4	$K(4,t) = (x_4 \cdot x_t + 1)^2 = (1 \cdot (-1) + 5 \cdot (-1) + 1)^2 = (-5)^2 = 25$	$(-0.125)(25)$
			-5
			$+$

$$f(\phi(x_t)) = \text{sign}(w \cdot \phi((1,5)) + b) = \text{sign}(-6.125 + 1.125 + 3.125 - 3.125 + 0) = \text{sign}(-5) \Rightarrow -1$$

Jadi data $x_t = (1,5)$ tersebut masuk ke kelas negatif.



Latihan Individu

1. Perhatikan dataset SVM Linier berikut :

x_1	x_2	Kelas (y)	Support Vector (SV)
1	1	+1	1
1	-1	-1	1
0	2	-1	1
-1	-1	-1	0

dataset 1

x_1	x_2	Kelas (y)	SV1	SV2
2	3	-1	1	0
3	4	-1	1	1
5	2	+1	1	1
6	3	+1	0	0

dataset 2

Tentukan Visualisasi Hyperplane masing-masing dataset di atas !

2. Perhatikan dataset SVM non-Linier berikut :

x_1	x_2	Kelas (y)	SV
0.5	0	-1	1
1	-1	+1	1
-1	1	+1	1
-0.5	-0.5	-1	1

Tentukan persamaan Hyperplanenya, lalu uji kelas data $x_t = (1, 1)$!

Terima kasih

